

Universidad de Guadalajara



Segunda Feria de Posgrados

---

# Clasificación de Imágenes con Deep Learning

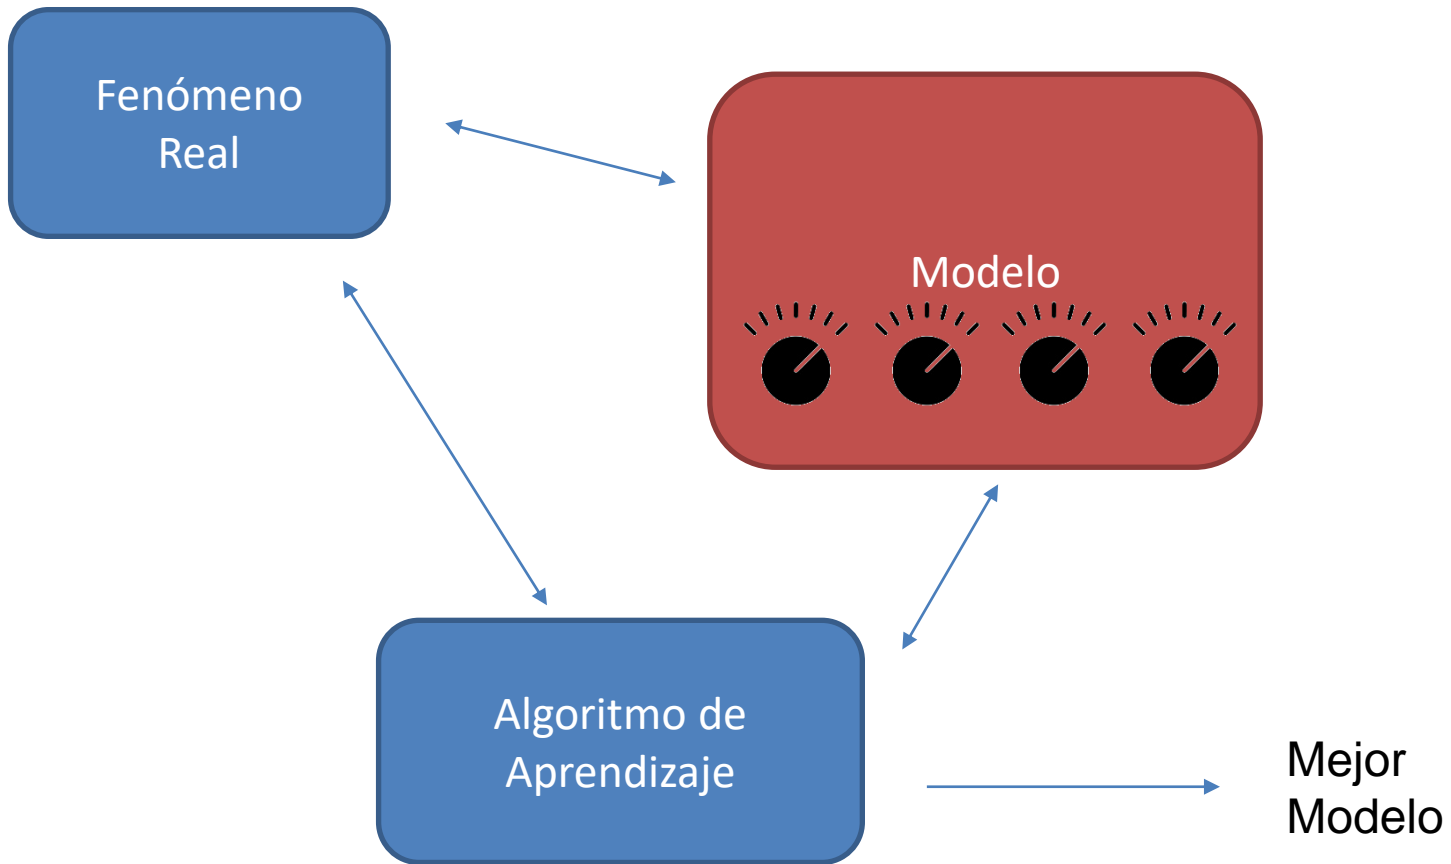
---

[https://github.com/Dr-Carlos-Villasenor/Taller\\_CNN](https://github.com/Dr-Carlos-Villasenor/Taller_CNN)

Dr. Carlos Villaseñor

- ¿Qué es Aprendizaje Automático?
- Introducción a redes neuronales densas
- Aprendizaje automático vs Aprendizaje profundo
- Introducción a redes neuronales convolucionales
- Transferencia de aprendizaje
- Búsqueda de hiperparámetros
- Poda neuronal

# ¿Qué es el aprendizaje automático?



# ¿Qué es el aprendizaje?

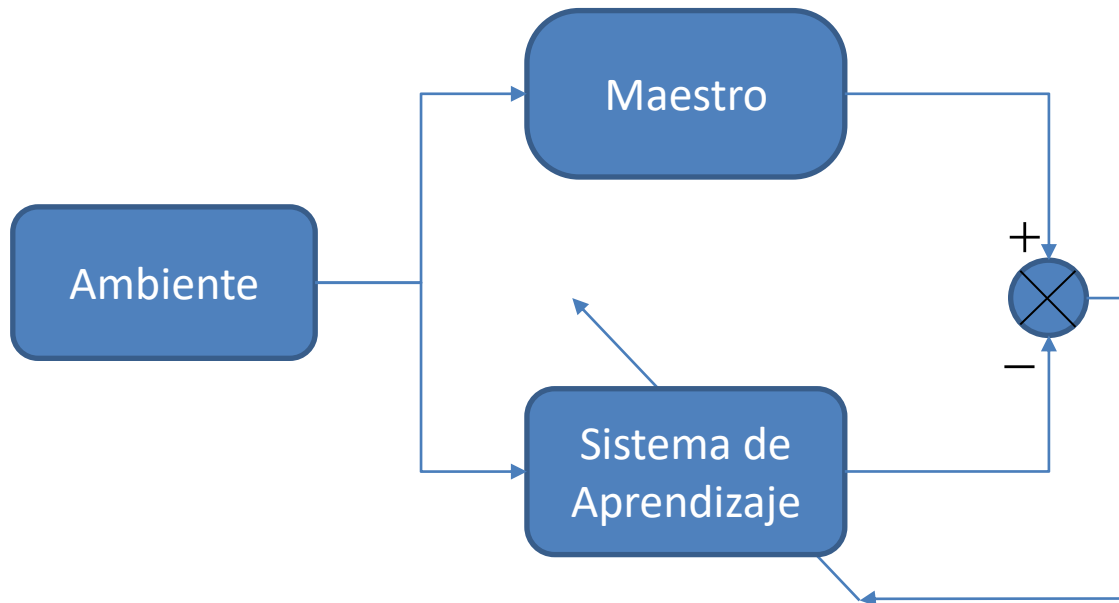


- Según Tom Mitchell:

“Decimos que un programa de computadora aprende de la experiencia  $E$  con respecto a la tarea  $T$  y medida de desempeño  $D$ , si su desempeño  $D$  sobre la tarea  $T$  aumenta con la experiencia  $E$ ”



# Aprendizaje supervisado



Nota: Existen otros dos paradigmas llamados Aprendizaje no supervisado y aprendizaje reforzado, estos están fuera del alcance de esta clase

# Problemas prototípicos




		Salida deseada	
		Discreta	Continua
Paradigma	Supervisado	Clasificación	Regresión
	No supervisado	Agrupamiento	Reducción de la dimensionalidad

# Introducción a las redes neuronales




- En 1906, Santiago Ramón y Cajal ganó el premio novel en medicina en reconocimiento de su trabajo sobre la estructura del sistema nervioso.
- Describió las neuronas como unidades de procesamiento de la información que se conectan y forman redes dinámicas para cumplir todas las funciones necesarias.



# La neurona biológica

## Estructura general de una neurona







# La neurona artificial




- En 1943, McCulloch y Pitts elaboraron el primer modelo matemático de una neurona



McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5(4), 115-133.

# La neurona artificial



$$w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$$

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

$$z = w^T x + b$$

$$\hat{y} = \varphi(z)$$

McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5(4), 115-133.



# El Perceptrón



Data:  $\left\{ \left( x^{(1)}, y^{(1)} \right), \left( x^{(2)}, y^{(2)} \right), \dots, \left( x^{(p)}, y^{(p)} \right) \right\}$

$$x^{(i)} \in \mathbb{R}^n, y^{(i)} \in \{0,1\}$$

For  $e \in \{1, 2, \dots, \text{epochs}\}$

For  $i \in \{1, 2, \dots, p\}$

$$\hat{y} = \varphi(w^T x^{(i)} + b)$$

$$w \leftarrow w + \eta(y^{(i)} - \hat{y})x^{(i)}$$

$$b \leftarrow b + \eta(y^{(i)} - \hat{y})$$



---


Rosenblatt, F. (1958). The perceptron: a probabilistic model for information storage and organization in the brain. Psychological review, 65(6), 386.

# Demo 1

# El Perceptrón




Perceptrón (compuerta AND)



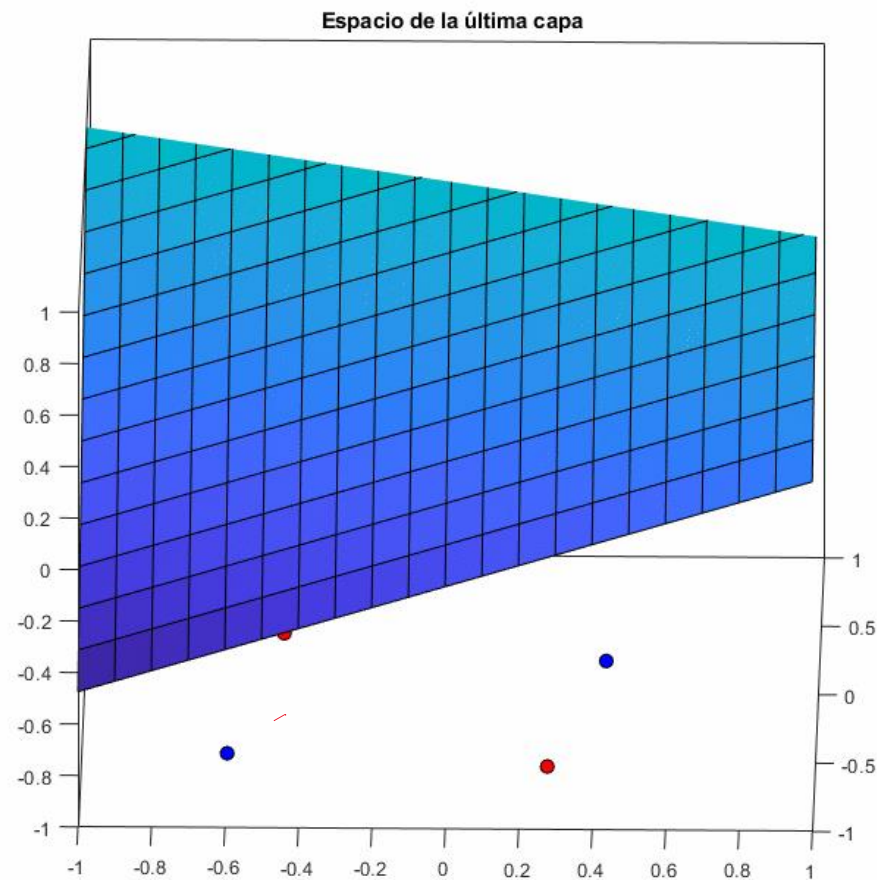

Rosenblatt, F. (1958). The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, 65(6), 386.



# Red neuronal densa




# Red neuronal densa




# Demo 2



# Backpropagation




# Backpropagation

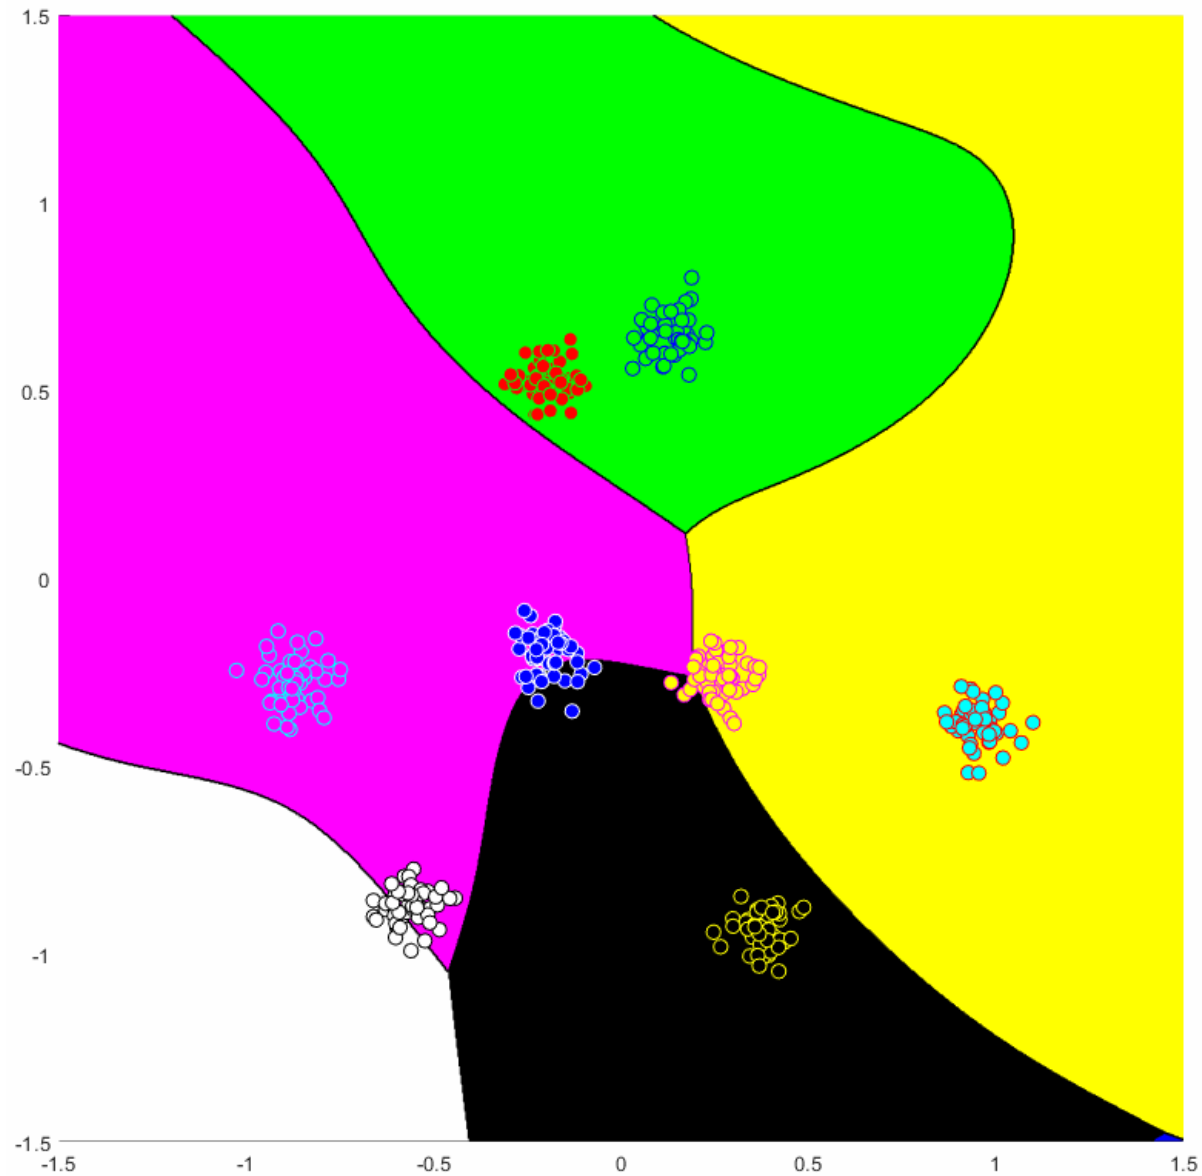




# Backpropagation




# MLP with Softmax



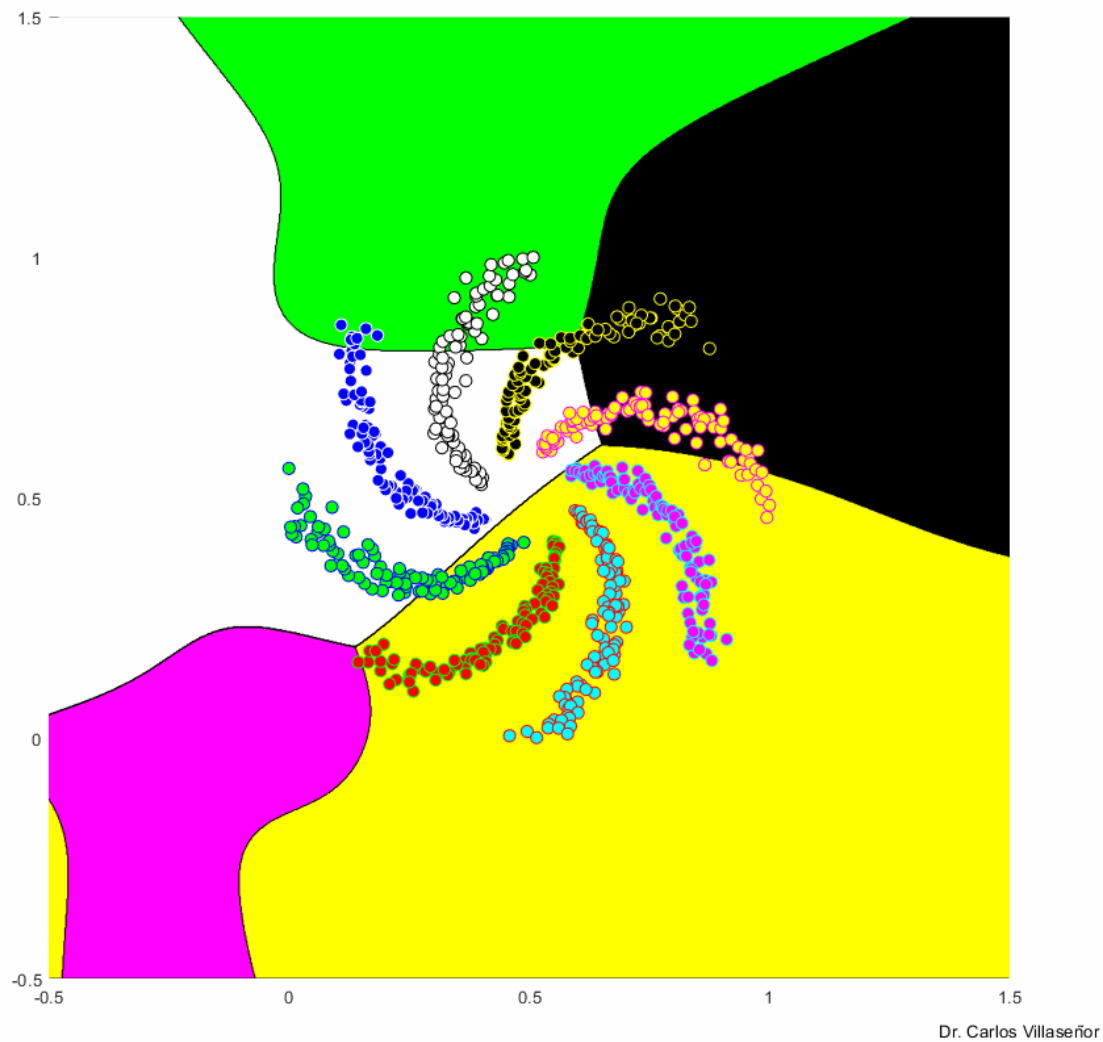
Dr. Carlos Villaseñor


# MLP with Softmax




Dr. Carlos Villaseñor


# MLP with Softmax













# Aprendizaje prodfungo



# Deep Learning



# Deep Learning vs Machine Learning





Desempeño



Datos



# Visión con una Red Neuronal



Si / No



Para una imagen de  $626 \times 417$  el número de píxeles que hay es de 261,042, multiplicando por 3 capas de color, obtenemos 783,126. Si en la primer capa oculta hay 5 neuronas, el total de parámetros en la primer capa es de 3,915,635

# Red Convolutiva



En 1989, Yann LeCun presentó una red que entrenaba filtros convolucionales con back-propagation.



3	0	1	2	7	4
1	5	8	9	3	1
2	7	2	5	1	3
0	1	3	1	7	8
4	2	1	6	2	8
2	4	5	2	3	9

$6 \times 6$

1	0	-1
2	0	-2
1	0	-1

$3 \times 3$

$=$

-12	-8	5	16
-10	0	3	5
-3	-2	-8	-14
0	-6	-4	-18


$4 \times 4$

$$n_h \times n_w * f \times f \rightarrow n_h - f + 1 \times n_w - f_2 + 1$$




# Convoluciones

9	9	9	0	0	0
9	9	9	0	0	0
9	9	9	0	0	0
9	9	9	0	0	0
9	9	9	0	0	0
9	9	9	0	0	0




\*




1	0	-1
1	0	-1
1	0	-1

=


0	27	27	0
0	27	27	0
0	27	27	0
0	27	27	0






$6 \times 6 \times 3$

\*




$3 \times 3 \times 3$

=







$4 \times 4$

# Múltiples filtros




$$8 \times 8 \times 3$$




$$3 \times 3 \times 3$$

Filtros=4


# Capa convolucional




$8 \times 8 \times 3$




$$\text{ReLU}\left(\begin{array}{|c|c|c|c|} \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline \end{array} + b_1\right)$$




$$\text{ReLU}\left(\begin{array}{|c|c|c|c|} \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline \end{array} + b_2\right)$$



$$\text{ReLU}\left(\begin{array}{|c|c|c|c|} \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline \end{array} + b_3\right)$$



$$\text{ReLU}\left(\begin{array}{|c|c|c|c|} \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline & & & \\ \hline \end{array} + b_4\right)$$



# Capa convolucional



$$n_h \times n_w \times n_c$$




$$f \times f \times n_c$$

$$s$$

$$p$$

$$n_f$$



$$\left\lfloor \frac{n_h + 2p - f}{s} + 1 \right\rfloor \times \left\lfloor \frac{n_w + 2p - f}{s} + 1 \right\rfloor \times n_f$$




# Conteo de parámetros



Para una imagen RGB de  $626 \times 417$  y si suponemos 5 filtros convolucionales de  $(3, 3)$  se tienen los siguientes parámetros:

$$5(3 \times 3 \times 3) + 5 = 140$$





# Pooling

Max-Pooling:

5	3	2	6
7	4	2	1
5	7	8	1
9	5	4	1




$$f = 2$$

$$s = 2$$


7	6
9	8



# Red Neuronal Convolutacional (CNN)

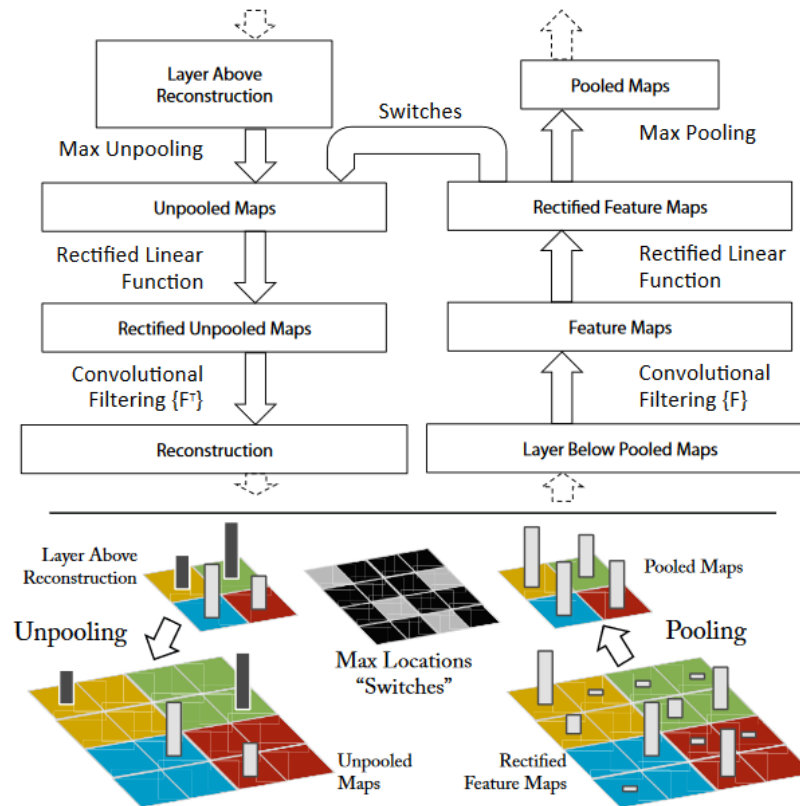


# Demo 3








- Dificultades de Deep Learning
  - Entrenar una red neuronal profunda puede durar semanas y requiere múltiples GPUs.
  - Se necesita una cantidad enorme de datos para lograr un buen desempeño en una arquitectura profunda.

# Aprendizaje de Transferencia


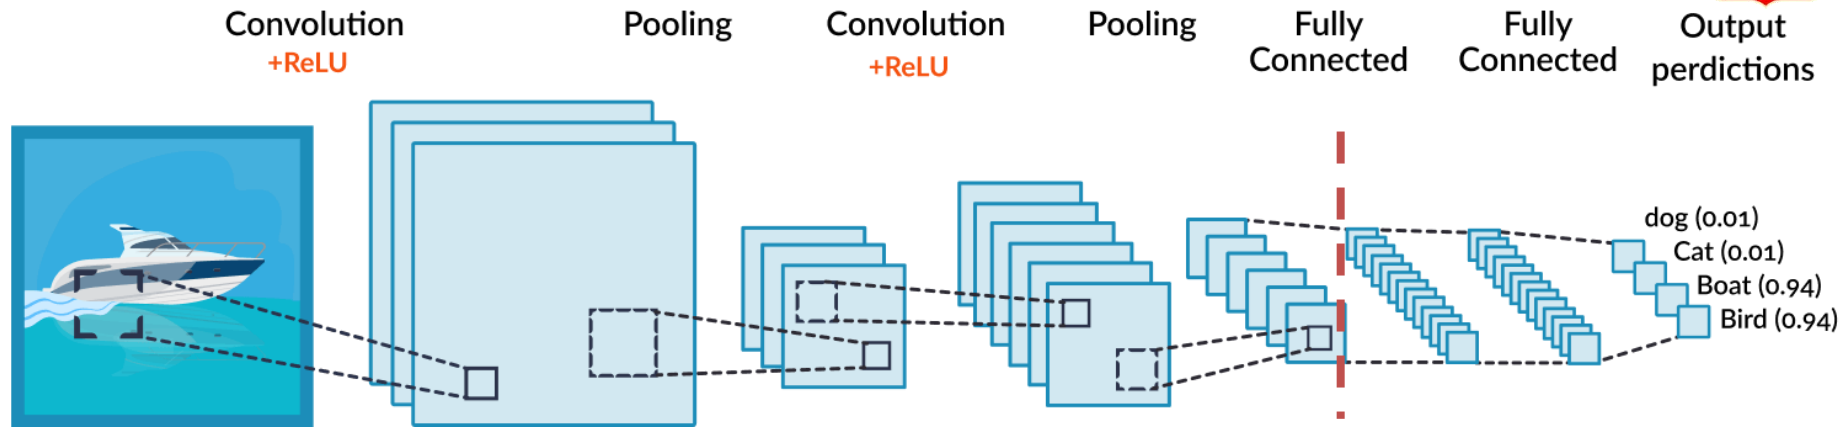


Zeiler, M. D., & Fergus, R. (2014, September). Visualizing and understanding convolutional networks. In *European conference on computer vision* (pp. 818-833). Springer, Cham.

# Aprendizaje de Transferencia

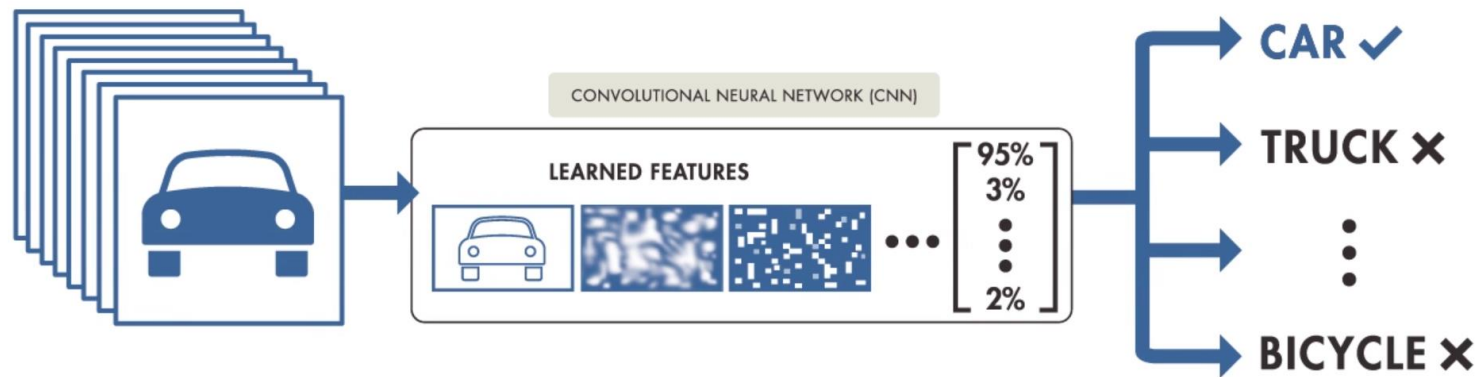


# Aprendizaje de Transferencia

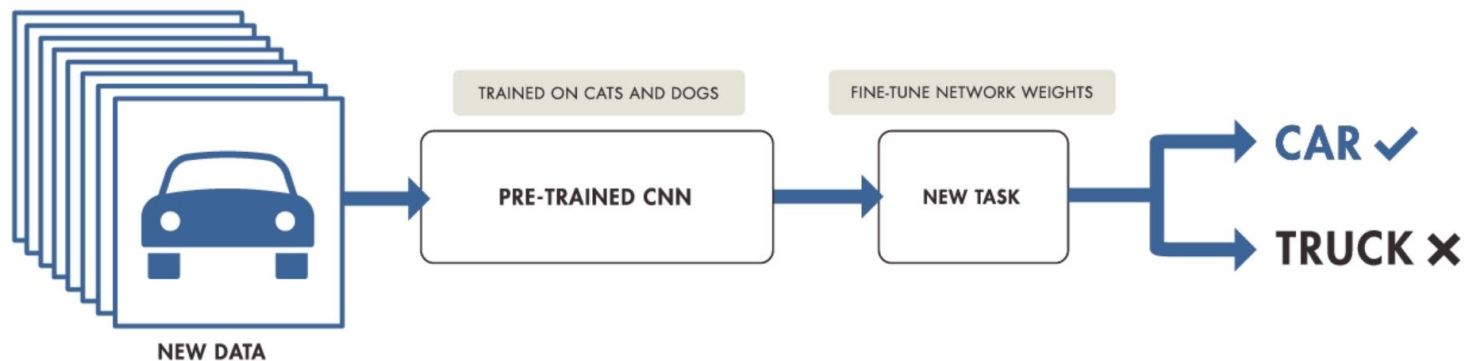


<https://missinglink.ai/guides/convolutional-neural-networks/convolutional-neural-network-tutorial-basic-advanced/>

## TRAINING FROM SCRATCH




## TRANSFER LEARNING






# Demo 4

# Búsqueda de hiperparámetros




Grid Search




Random Search

# Hyperband




(a) Configuration Selection



(b) Configuration Evaluation

# Demo 5


# ¿Para qué podar la red artificial ?



- Normalmente tenemos

$\arg \min_w L(x; W)$   
cuándo hacemos poda suponemos

- Características del podado  $\|W_p\|_0 \leq N$ 
  1. Granularidad
  2. Criterio de poda
  3. Radio de poda
  4. Entrenamiento fino de red podada



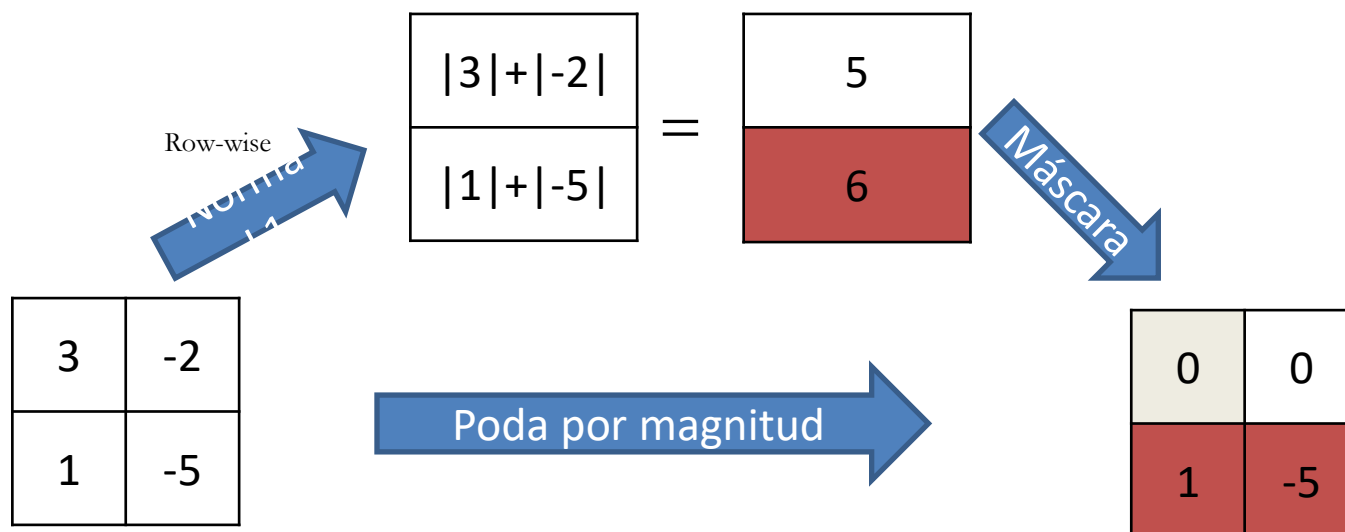
# Criterio de poda



Existen muchos criterios de poda, a continuación veremos los más importantes

- Basados en la magnitud (Magnitud-based pruning)

$$\text{importancia} = |w|$$



- Existen dos métodos populares

- ConstantSparsity

- La dispersión se mantiene constante durante el entrenamiento

Args
target_sparsity
begin_step
end_step
frequency

- PolynomialDecay

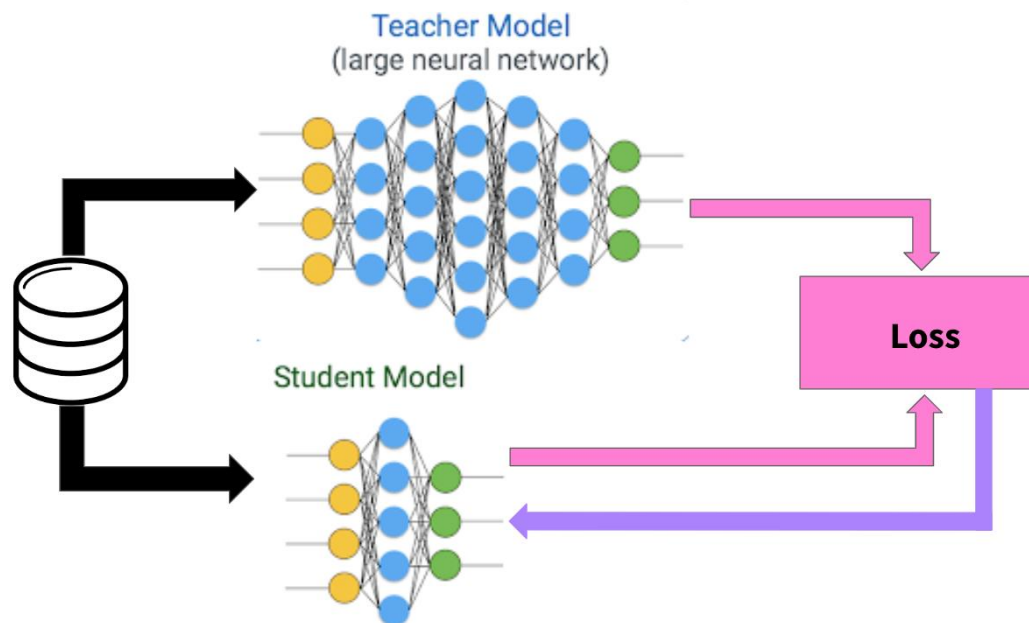
- La dispersión va aumentando junto con el entrenamiento

Args
initial_sparsity
final_sparsity
begin_step
end_step
power
frequency


o




# Destilación del conocimiento



# Red evaluada en otros sistemas numéricos



# Cuantización de una red



# Demo 6

# Fin del curso